

GMDL212, HW1

Yuval Margalit

Part I

Random Vectors

Problem 1:

יהיו A_1, \dots, A_n סדרת מאורעות זרים בזוגות נראה כי $P(\bigcup_{i=1}^n A_i) = \sum_{i=1}^n P(A_i)$ נשלים את הסדרה לסדרה אינסופית $A_1, \dots, A_n, A_{n+1}, \dots$ כך ש $A_{n+1} = A_{n+2} = \dots = \emptyset$ אז $P(\bigcup_{i=1}^n A_i) = P(\bigcup_{i=1}^\infty A_i) \stackrel{P(\emptyset)=0}{=} \sum_{i=1}^\infty P(A_i) \stackrel{\text{property 3}}{=} \sum_{i=1}^n P(A_i)$

Problem 2:

יהי A מאורע נראה כי $P(A^c) = 1 - P(A)$
 $\Omega = A \cup A^c \Rightarrow 1 = P(\Omega) = P(A \cup A^c) \stackrel{\text{fact 1}}{=} P(A) + P(A^c) \Rightarrow P(A^c) = 1 - P(A)$

Problem 3:

יהי X וקטור רנדומי אשר הטווח שלו הוא \mathbb{R}
1. נניח $B = \mathbb{R}$ אז $X^{-1}(B) = \{\omega \in \Omega | X(\omega) \in B\} = \{\omega \in \Omega | X(\omega) \in \mathbb{R}\} \stackrel{F(x) \subset \mathbb{R}}{=} \Omega$ ולכן $P(X^{-1}(B)) = P(\Omega) = 1$
2. נניח $B = \emptyset$ אז $X^{-1}(B) = \{\omega \in \Omega | X(\omega) \in B\} = \{\omega \in \Omega | X(\omega) \in \emptyset\} = \emptyset$ ולכן $P(X^{-1}(B)) = P(\emptyset) = 0$

Problem 4:

אראה כי F אינה רציפה מימין ב 42 ולכן לא יכול להיות CDF
 $\lim_{x \rightarrow 42^+} F(x) = 1$ אבל $F(42) = 0$ ולכן F אינה רציפה מימין

Problem 5:

יהי X וקטור רדומי רציף n מימדי

$$1. \quad P(X = x) = \lim_{x' \rightarrow x^-} P(x' < X \leq x) = F(x) - \lim_{x' \rightarrow x} F(x') \\ F(x) - \lim_{x' \rightarrow x^-} F(x') = F(x) - F(x) = 0 \text{ ולכן } F$$

$$2. \quad \text{בעבור } B = \{(1, \dots, 1)^T\}_{n\text{-times}} \text{ יתקיים כי } P(X^{-1}(B)) = F(X = (1, \dots, 1)^T) \stackrel{1}{=} 0$$


$$3. \quad \forall i \geq 1, B_i = \{(i, \dots, i)^T\}_{n\text{-times}}$$


נשים לי כי אכן $\forall i, j \geq 1, i \neq j \rightarrow B_i \cap B_j = \emptyset$ נתבונן ב $X^{-1}(\bigcup_{i=1}^{\infty} B_i)$ נשים לב שכיוון ו X הוא פונקציה מתקיים $\forall i, j \geq 1, i \neq j \rightarrow$

$$X^{-1}(B_i) \cap X^{-1}(B_j) = \emptyset$$

$$\text{ולכן } P(X^{-1}(\bigcup_{i=1}^{\infty} B_i)) = \sum_{i=0}^{\infty} P(X^{-1}(\bigcup_{i=1}^{\infty} B_i)) = \text{אז מתכונה 3 של פונקציות הסתברות} \\ \sum_{i=0}^{\infty} 0 = 0$$

problem 6:





problem 7:

$$p(x_3, x_4, x_5) = \sum_{x_1, x_2} p(x)$$

problem 8:

$$E(X) = \sum_{i=1}^6 P(X=i)i = \frac{1}{6} \sum_{i=1}^6 i = \frac{21}{6} = 3.5$$

problem 9:

$$(xx^T)^T = (x^T)^T x^T = xx^T$$

problem 10:

$$E(X^T) = E(g(X)) = \sum_x g(x)p(x) = \sum_x x^T p(x) = \left(\sum_x xp(x)\right)^T = \mu^T$$

נניח $E(X) = \mu$ ונגדיר $g(x) = x^T$
באופן דומה הדבר נכון גם למקרה הרציף

problem 11:

$$E(XX^T) = E(g(X)) \text{ ונגדיר } g(x) = xx^T$$

$$E(XX^T)_{i,j} = E(g(X))_{i,j} = E((g(X))_{ij}) = E(X_i X_j)$$

problem 12:

$$(R_x)^T = E(XX^T)^T \stackrel{\text{problem 10}}{=} E((XX^T)^T) \stackrel{\text{problem 9}}{=} E(XX^T) = R_x$$

problem 13:

$$\Sigma_X = E(g(X)) \text{ ונגדיר } g(x) = (x - E(x))(x - E(x))^T$$

$$(\Sigma_X)_{i,j} = E(g_{i,j}(X)) = E((X - E(X))_i (X - E(X))^T_j) = E((X_i - \mu_i)(X_j - \mu_j)) = \text{cov}(X_i, X_j)$$

problem 14:

$$(\Sigma_X)_{i,i} \stackrel{\text{problem 13}}{=} E((X_i - \mu_i)(X_i - \mu_i)) = E((X_i - \mu_i)^2) = V(X_i)$$

problem 15:

$$(\Sigma_X)^T = (E((X - \mu)(X - \mu)^T))^T \stackrel{\text{problem 9}}{=} E(((X - \mu)^T)^T (X - \mu)^T) = E((X - \mu)(X - \mu)^T)$$

problem 16:

1.

$$\begin{aligned} \Sigma_X &= E((X - \mu)(X - \mu)^T) = E(XX^T - X\mu^T - \mu X^T + \mu\mu^T) \stackrel{\text{mean-is-linear}}{=} \\ &= E(XX^T) - E(X\mu^T) - E(\mu X^T) + E(\mu\mu^T) \stackrel{\text{problem-10}}{=} \\ &= E(XX^T) - \mu\mu^T - \mu\mu^T + \mu\mu^T = E(XX^T) - \mu\mu^T \end{aligned}$$

2.

$$E((X - \mu)X^T) = E(XX^T - \mu X^T) \stackrel{\text{mean-is-linear}}{=} E(XX^T) - E(\mu X^T) \stackrel{\text{problem-10}}{=} E(XX^T) - \mu\mu^T = \Sigma_X$$

3.

$$E(X(X - \mu)^T) = E(XX^T - X\mu^T) \stackrel{\text{mean-is-linear}}{=} E(XX^T) - E(X\mu^T) \stackrel{\text{problem-10}}{=} E(XX^T) - \mu\mu^T = \Sigma_X$$

$E(c)=c$

problem 17:

1.

$$R_{XY} = E(XY^T), R_{YX} = E(YX^T), R_{XY}^T = (E(XY^T))^T \stackrel{\text{problem-10}}{=} E((Y^T)^T X^T) = E(YX^T) = R_{YX}$$

2.

$$\begin{aligned} \Sigma_{XY}^T &= (E((X - E(X))(Y - E(Y))^T))^T \stackrel{\text{problem-10}}{=} E(((X - E(X))(Y - E(Y))^T)^T) \\ &= E(((Y - E(Y))^T)^T (X - E(X))^T) = E((Y - E(Y))(X - E(X))^T) = \Sigma_{YX} \end{aligned}$$

3.

$$\begin{aligned} \Sigma_{XY}^T &= (E((X - E(X))(Y - E(Y))^T))^T = E(XY^T - X((E(Y))^T - E(X)Y^T + E(X)(E(Y))^T) \stackrel{\text{mean-is-linear}}{=} \\ &= E(XY^T) - E(X(E(Y))^T) - E(E(X)Y^T) + E(E(X)(E(Y))^T) \stackrel{\substack{E(cX) = cE(X) \\ E(c) = c}}{=} \\ &= E(XY^T) - E(X)(E(Y))^T - E(X)E(Y^T) + E(X)(E(Y))^T \stackrel{\text{problem-10}}{=} E(XY^T) - \mu_X \mu_Y^T - \mu_X \mu_Y^T + \mu_X \mu_Y^T \stackrel{\text{definition-27}}{=} \\ &= R_{XY} - \mu_X \mu_Y^T \end{aligned}$$

problem 18:

$$\mu_Y = E(Y) = E(AX + b) \stackrel{\text{mean-is-linear}}{=} E(AX) + E(B) = AE(X) + b = A\mu_X + b$$

$$\begin{aligned} \Sigma_Y &= E((Y - E(Y))(Y - E(Y))^T) = E((AX + b - A\mu_X - b)((AX + b - A\mu_X - b)^T) = \\ &= E((AX - A\mu_X)((AX - A\mu_X)^T) = E(A(X - \mu_X)(X - \mu_X)^T A^T) = \\ &= AE((X - \mu_X)(X - \mu_X)^T)A^T = A\Sigma_X A^T \end{aligned}$$

problem 19:

יהי X וקטור רנדומי מממד N עם תוחלת μ וקובריאנס $\Sigma_X = \sigma^2 I$ כאשר I מטריצת היחידה מסדר n ו $\sigma > 0$

נסמן $Y = 1^T X = \sum_{i=1}^n X_i$ אז מהשאלה הקודמת $\Sigma_Y = 1^T \Sigma_X 1 = (\sigma^2 1)^T 1 = \sum_{i=1}^n \sigma^2 = n\sigma^2$

problem 20:

יהיו A, B, C מאורעות.

\Leftarrow נניח $A \perp B|C$ אז $P(A|B, C) = \frac{P(A \cap B \cap C)}{P(B \cap C)} = \frac{P(A, B|C)P(C)}{P(B|C)P(C)} = \frac{P(A|C)P(B|C)P(C)}{P(B|C)P(C)} = P(A|C)$

\Rightarrow נניח $P(A|B, C) = P(A|C)$ אז $\frac{P(A \cap C)}{P(C)} = \frac{P(A \cap B \cap C)}{P(B \cap C)}$

$P(A, B|C) = \frac{P(A \cap B \cap C)}{P(C)} = \frac{P(A \cap B \cap C)P(B \cap C)}{P(B \cap C)P(C)} = \frac{P(A \cap C)P(B \cap C)}{P(C)P(C)} = P(A|C)P(B|C)$

problem 21:

$$E(\mathbb{1}_A) = \sum_{i=0}^1 P(\mathbb{1}_A = i) * i = P(\mathbb{1}_A = i) = P(A)$$

problem 22:

יהיו $X \in R^n, Y \in R^m$ וקטורים מקריים אורטוגונליים כלומר $E(XY^T) = 0_{m \times n}$

$$R_Z = E(ZZ^T) \stackrel{problem-11}{=} \begin{bmatrix} E(XX^T) & E(XY^T) \\ E(YX^T) & E(YY^T) \end{bmatrix} = \begin{bmatrix} R_X & 0 \\ 0 & R_Y \end{bmatrix}$$

יהיו $X \in R^n, Y \in R^m$ וקטורים מקריים חסרי קורלציה כלומר $E(XY^T) = \mu_X \mu_Y^T$ אז

$$\Sigma_Z \stackrel{fact-9}{=} \begin{bmatrix} \Sigma_X & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_Y \end{bmatrix} \stackrel{Definition-27}{=} \begin{bmatrix} \Sigma_X & E(XY^T) - \mu_X \mu_Y^T \\ E(YX^T) - \mu_Y \mu_X^T & \Sigma_Y \end{bmatrix} = \begin{bmatrix} \Sigma_X & 0 \\ 0 & \Sigma_Y \end{bmatrix}$$

problem 23:

יהיו X, Y וקטורים רנדומיים ונניח $X \perp\!\!\!\perp Y$ מהגדרה $p(x, y) = p(x)p(y)$

$$E(XY^T) = \sum_{x,y} xy^T p(x, y) = \sum_x \sum_y xy^T p(x)p(y) \stackrel{sum-is-linear}{=} \sum_x xp(x) (\sum_y y^T p(y)) \stackrel{problem-10}{=} \sum_x xp(x) E(Y^T) = E(X)(E(Y))^T$$

ההוכחה זהה למקרה הרציף כיוון ואינטגרל הינו לינארי

problem 24:

$$p(X_1) = \sum_{x_2} p(x_1, x_2) = p(x_1, 0) + p(x_1, 1) = \begin{cases} 0.6 & x_1 = 0 \\ 0.4 & x_1 = 1 \end{cases} .1$$

$$p(X_1) = \sum_{x_1} p(x_1, x_2) = p(0, x_2) + p(1, x_2) = \begin{cases} 0.8 & x_2 = 0 \\ 0.2 & x_2 = 1 \end{cases}$$

$$E(X) \stackrel{Definition-20}{=} \begin{bmatrix} E(X_1) \\ E(X_2) \end{bmatrix} = \begin{bmatrix} 0.4 \\ 0.2 \end{bmatrix} .2$$

$$R_X = E(XX^T) \stackrel{problem-11}{=} \begin{bmatrix} E(X_1^2) & E(X_1 X_2) \\ E(X_2 X_1) & E(X_2^2) \end{bmatrix} = \begin{bmatrix} 0.4 & 0.08 \\ 0.08 & 0.2 \end{bmatrix} .3$$

$$\Sigma_X \stackrel{fact-8}{=} E(XX^T) - \mu_X \mu_X^T = \begin{bmatrix} 0.4 & 0.08 \\ 0.08 & 0.2 \end{bmatrix} - \begin{bmatrix} 0.4 \\ 0.2 \end{bmatrix} \begin{bmatrix} 0.4 & 0.2 \end{bmatrix} = \begin{bmatrix} 0.4 & 0.08 \\ 0.08 & 0.2 \end{bmatrix} - \begin{bmatrix} 0.16 & 0.08 \\ 0.08 & 0.04 \end{bmatrix} = \begin{bmatrix} 0.24 & 0 \\ 0 & 0.16 \end{bmatrix} .4$$

5. X_1, X_2 אינם בלתי תלויים כיוון ש $p(X_1 = 1, X_2 = 1) = 0.1 \neq 0.08 = 0.4 * 0.2 = p(X_1 = 1)p(X_2 = 1)$ כלומר פונקציית ההתפלגות המשותפת אינה מכפלה של ההתפלגויות השוליות

6. X_1, X_2 חסרי קורלציה כיוון ו $E(X_1 X_2) = 0.08 = 0.4 * 0.2 = E(X_1)E(X_2)$

probelm 25:

$$p(X_1) = \sum_{x_2} p(x_1, x_2) = p(x_1, 0) + p(x_1, 1) = \begin{cases} 0.5 & x_1 = 0 \\ 0.5 & x_1 = 1 \end{cases} .1$$

$$p(X_1) = \sum_{x_1} p(x_1, x_2) = p(0, x_2) + p(1, x_2) = \begin{cases} 0.5 & x_2 = 0 \\ 0.5 & x_2 = 1 \end{cases}$$

$$E(X) \stackrel{Definition20}{=} \begin{bmatrix} E(X_1) \\ E(X_2) \end{bmatrix} = \begin{bmatrix} 0.5 \\ 0.5 \end{bmatrix} .2$$

$$E(XX^T) \stackrel{probelm-11}{=} \begin{bmatrix} E(X_1^2) & E(X_1X_2) \\ E(X_2X_1) & E(X_2^2) \end{bmatrix} = \begin{bmatrix} 0.5 & 0.25 \\ 0.25 & 0.5 \end{bmatrix} .3$$

$$\Sigma_X \stackrel{fact-8}{=} E(XX^T) - \mu_X \mu_X^T = \begin{bmatrix} 0.5 & 0.25 \\ 0.25 & 0.5 \end{bmatrix} - \begin{bmatrix} 0.5 \\ 0.5 \end{bmatrix} \begin{bmatrix} 0.5 & 0.5 \end{bmatrix} = \begin{bmatrix} 0.5 & 0.25 \\ 0.25 & 0.5 \end{bmatrix} - \begin{bmatrix} 0.25 & 0.25 \\ 0.25 & 0.25 \end{bmatrix} = \begin{bmatrix} 0.25 & 0 \\ 0 & 0.25 \end{bmatrix}$$

$$\forall 0 \leq i, j \leq 1, p(i, j) = 0.25 = 0.5 * 0.5 = p(i) * p(j) \text{ ו } X_1, X_2 \text{ בלתי תלויים כיוון } .4$$

$$\text{כיוון ו } X_1, X_2 \text{ בלתי תלויים הם גם חסרי קורלציה (המשפט משאלה 23 קיים גם למשתנים מקריים סקלריים (מקרה פרטי))} .5$$

$$\forall y \in \Omega, Y_1(y) \in \{0, 1, 2\}, Y_2(y) \in \{0, 1\} \text{ כי } .6$$

$X_1 \backslash X_2$	0	1
0	$Y_1 = 0, Y_2 = 0$	$Y_1 = 1, Y_2 = 1$
1	$Y_1 = 1, Y_2 = 1$	$Y_1 = 2, Y_2 = 0$

נתבונן בטבלה הבאה:

מהטבלה ניתן לראות כי קיימים רק 3 צירפונים אפשריים של Y_1 ו Y_2

$$p_{Y_1, Y_2}(0, 0) = p_X(0, 0) = 0.25$$

$$p_{Y_1, Y_2}(1, 1) = p_X(1, 0) + p_X(0, 1) = 0.25 + 0.25 = 0.5$$

$$p_{Y_1, Y_2}(2, 0) = p_X(1, 0) = 0.25$$

$$p_{Y_1}(y_1) = \sum_{y_2} p_{Y_1, Y_2}(y_1, y_2) = p_{Y_1, Y_2}(y_1, 0) + p_{Y_1, Y_2}(y_1, 1) = \begin{cases} 0.25 & y_1 = 0 \\ 0.5 & y_1 = 1 \\ 0.25 & y_1 = 2 \end{cases} .7$$

$$p_{Y_2}(y_2) = \sum_{y_1} p_{Y_1, Y_2}(y_1, y_2) = p_{Y_1, Y_2}(0, y_2) + p_{Y_1, Y_2}(1, y_2) + p_{Y_1, Y_2}(2, y_2) = \begin{cases} 0.5 & y_2 = 0 \\ 0.5 & y_2 = 1 \end{cases}$$

$$E(Y) \stackrel{Definition20}{=} \begin{bmatrix} E(Y_1) \\ E(Y_2) \end{bmatrix} = \begin{bmatrix} 1 \\ 0.5 \end{bmatrix} .8$$

$$E(YY^T) \stackrel{problem-11}{=} \begin{bmatrix} E(Y_1^2) & E(Y_1Y_2) \\ E(Y_1Y_2) & E(Y_2^2) \end{bmatrix} = \begin{bmatrix} 1.5 & 0.5 \\ 0.5 & 0.5 \end{bmatrix} \quad 9$$

$$\Sigma_X \stackrel{fact-8}{=} E(YY^T) - \mu_X \mu_X^T = \begin{bmatrix} 1.5 & 0.5 \\ 0.5 & 0.5 \end{bmatrix} - \begin{bmatrix} 1 \\ 0.5 \end{bmatrix} \begin{bmatrix} 1 & 0.5 \end{bmatrix} = \begin{bmatrix} 1.5 & 0.5 \\ 0.5 & 0.5 \end{bmatrix} - \begin{bmatrix} 1 & 0.5 \\ 0.5 & 0.25 \end{bmatrix} = \begin{bmatrix} 0.5 & 0 \\ 0 & 0.25 \end{bmatrix}$$

10. Y_1, Y_2 אינם בלתי תלויים כיוון ש $p(Y_1 = 1, Y_2 = 1) = 0.5 \neq 0.25 = 0.5 * 0.5 = p(Y_1 = 1)p(Y_2 = 1)$
כלומר פונקציית ההתפלגות המשותפת אינה מכפלה של ההתפלגויות השוליות

11. Y_1, Y_2 חסרי קורלציה כיוון ו $E(Y_1Y_2) = 0.5 = 1 * 0.5 = E(Y_1)E(Y_2)$

problem 26:

יהיו X, Y, Z וקטורים מקריים ויהיו x, y, z ערכים אפשריים שלהם בהתאמה

$$\Rightarrow \text{נניח } X \perp\!\!\!\perp Y|Z \text{ אז } P(x|y, z) = \frac{P(x, y, z)}{P(y, z)} = \frac{P(x, y|z)P(z)}{P(y|z)P(z)} = \frac{P(x|z)P(y|z)P(z)}{P(y|z)P(z)} = P(x|z)$$

$$\Rightarrow \text{נניח } P(x|y, z) = P(x|z) \text{ אז } \frac{P(x, z)}{P(z)} = \frac{P(x, y, z)}{P(y, z)} \text{ אז } P(x, y, z) = \frac{P(x, z)P(y, z)}{P(z)}$$

$$P(x, y|z) = \frac{P(x, y, z)}{P(z)} = \frac{P(x, y, z)P(y, z)}{P(y, z)P(z)} = \frac{P(x, z)P(y, z)}{P(z)P(z)} = P(x|z)P(y|z)$$

problem 27:

1. נשים לב כי $\forall x, y, z \in \mathbb{R} \exp(x+xz+yz) = \exp(x+xz) * \exp(yz)$ ניתן להגדיר

$$f(x, z) = \begin{cases} \exp(x + xz) & (x, z) \in B \\ 0 & \text{otherwise} \end{cases}, g(y, z) = \begin{cases} \exp(yz) & (y, z) \in B \\ 0 & \text{otherwise} \end{cases}$$

ויתקבל כי $X \perp\!\!\!\perp Y|Z$ 18 ולכן מעובדה $p(x, y, z) \propto f(x, z)g(y, z)$

2. נשים לב כי $\exp(xyz) = (\exp(xy))^z$. ולכן יהיה קייפ פירוק כמו בעובדה 18 רק אם קיימת פקטורזציה ל $\exp(xy)$ לשתי פונקציות במשתנה יחיד.

לא קיים פירוק כזה ולכן לא קיים פירוק מתאים ל $\exp(xyz)$ ולכן מעובדה 18 $X \not\perp\!\!\!\perp Y|Z$

Part II

Markov Chains

problem 1:

(d)

y_3	$p(y_3)$
0	$(1 - \theta)^3$
1	$\binom{3}{1}\theta(1 - \theta)^2 = 3\theta(1 - \theta)^2$
2	$\binom{3}{2}\theta^2(1 - \theta) = 3\theta^2(1 - \theta)$
3	θ^3

(i)

$$p(y_3|x_1, x_2, y_1) \stackrel{Y_1=X_1}{=} p(y_3|x_1, x_2) \stackrel{h}{=} \begin{cases} x_1 + x_2 & \text{with probability } \theta \\ x_1 + x_2 + 1 & \text{with probability } \theta \end{cases}$$

(j)

$$p(y_3|x_1, x_2, y_2) = p(y_3|y_2) = \begin{cases} y_2 & \text{with probability } \theta \\ y_2 + 1 & \text{with probability } \theta \end{cases}$$

(k)

נשים לב כי $Y_3 = X_3 + X_2 + X_1 = X_3 + Y_2$ ולכן

$$p(y_3|x_1, x_2, x_3, y_2) = p(y_3|x_3, y_2) = 1^{1_{y_3=x_3+y_2}}$$

(l)

$$p(y_3|y_1, y_2, y_3) = p(y_3|y_3) = 1^{1_{y_3=y_3}}$$

problem 2:

יהיו $P_1, P_2 \in M_{n \times n}$ מטריצות מעבר של שרשראות מרקוב נראה כי $P_3 = P_1 P_2$ הינה מטריצת מעבר של שרשרת מרקוב כלשהי.

• יהיו $1 \leq i, j \leq n$ נראה כי $0 \leq (P_3)_{i,j} \leq 1$.

$$(P_3)_{ij} = \sum_{k=1}^n (P_1)_{ik} (P_2)_{kj}$$

כיוון ו P_2 מטריצת מעבר אז $\forall 0 \leq l, m \leq n, (P_2)_{lm} \leq 1$ ולכן

$$(P_3)_{ij} = \sum_{k=1}^n (P_1)_{ik} (P_2)_{kj} \leq \sum_{k=1}^n (P_1)_{ik} = 1$$

בנוסף כיוון וכל הכניסות ב P_1, P_2 אי שליליות בהכרח $(P_3)_{ij} \geq 0$.

•

$$\begin{aligned} \sum_{j=0}^n (P_3)_{ij} &= \sum_{j=0}^n \sum_{k=1}^n (P_1)_{ik} (P_2)_{kj} = \sum_{k=0}^n \sum_{j=1}^n (P_1)_{ik} (P_2)_{kj} = \\ &= \sum_{k=0}^n (P_1)_{ik} \sum_{j=1}^n (P_2)_{kj} \stackrel{eq. 21}{=} \sum_{k=0}^n (P_1)_{ik} \stackrel{eq. 21}{=} 1 \end{aligned}$$

problem 3:

על $P(X_{n+1} = j | X_0 = i) = \sum_{k=1}^n P(X_{n+1} = j, X_n = k | X_0 = i)$ כל ערכי X_n
 $= \sum_{k=1}^n P(X_{n+1} = j | X_n = k, X_0 = i) P(X_n = k | X_0 = i)$ נובע מכלל בייס
 $P(x_n | x_1, \dots, x_{n-1}) = P(x_n | x_{n-1})$ נובע ממרקוביות $\sum_{k=1}^n P(X_{n+1} = j | X_n = k) P(X_n = k | X_0 = i)$
 $\sum_{k=1}^n P(X_n = k | X_0 = i) P(X_{n+1} = j | X_n = k)$ קומטטביות כפל של סקלרים
 $\sum p_n(i, k) p(k, j)$ לפי הגדרה להסתברות לעבור בא צעדים בשרשרת מרקוב
 $(the\ i - th\ row\ of\ P^n)\ times\ (the\ j - th\ column\ of\ P)$ מהנחת האינדוקציה ומקרה הבסיס
 $= the\ (i, j)\ entry\ of\ P^n$ מהגדרת כפל מטריצות

problem 4:

$$\begin{aligned} \pi_0 P^n &= \begin{bmatrix} \sum_{k=1}^N (\pi_0)_k P_{1k} & \dots & \sum_{k=1}^N (\pi_0)_k P_{Nk} \end{bmatrix} \stackrel{problem\ 3}{=} \begin{bmatrix} \sum_{k=1}^N P(X_0 = k) P(X_n = i | X_0 = k) & \dots & \sum_{k=1}^N P(X_0 = k) P(X_n = N | X_0 = k) \end{bmatrix} = \\ &\stackrel{bayes}{=} \begin{bmatrix} \sum_{k=1}^N P(X_n = i, X_0 = k) & \dots & \sum_{k=1}^N P(X_n = N, X_0 = k) \end{bmatrix} \stackrel{marginal}{=} \begin{bmatrix} \sum_{k=1}^N P(X_n = i) & \dots & \sum_{k=1}^N P(X_n = N) \end{bmatrix} \end{aligned}$$

problem 5:

תהי P מטריצת מעברים מגודל $N \times N$ אשר כל שורתיה זהות ויהי $P = \begin{bmatrix} \pi \\ \vdots \\ \pi \end{bmatrix}$ עבור וקטור התפלגות כלשהו π מגודל $1 \times N$

(a)

$$P_{ij}^2 = \sum_{k=1}^N P_{ik} P_{kj} = \sum_{k=1}^N P_{ik} \pi_j = \pi_j \sum_{k=1}^N P_{ik} \stackrel{\pi \text{ is distribution}}{=} \pi_j = P_{ij}$$

(b)

אוכיח באינדוקציה על n .
בסיס: הוכח בסעיף הקודם, נניח שהטענה נכונה עבור n נראה עבור $n+1$
 $P^{n+1} = P^n P$ אז מהנחת האינדוקציה $P^2 = P$

(c)

$$\tilde{\pi} P = \begin{bmatrix} \sum_{k=1}^N \tilde{\pi}_k P_{1k} & \dots & \sum_{k=1}^N \tilde{\pi}_k P_{Nk} \end{bmatrix} = \begin{bmatrix} \sum_{k=1}^N \pi_1 \tilde{\pi}_k & \dots & \sum_{k=1}^N \pi_N \tilde{\pi}_k \end{bmatrix} = \begin{bmatrix} \pi_1 \sum_{k=1}^N \tilde{\pi}_k & \dots & \pi_N \sum_{k=1}^N \tilde{\pi}_k \end{bmatrix} \stackrel{\sum_{i=1}^N \tilde{\pi}_i = 1}{=} \begin{bmatrix} \pi_1 & \dots & \pi_N \end{bmatrix} = \pi$$

(d)

יהיו $n \geq 1$ ו π_0 וקטור התפלגות כלשהו מגודל $1 \times N$
 $\pi_n \stackrel{fact 1}{=} \pi_0 P^{n-1} \stackrel{(b)}{=} \pi_0 P \stackrel{(c)}{=} \pi$

Part III

SPD Matrices, Inner Products, Norms, and Metrics

problem 1:

תהי A מטריצת SPD מעובדה 1 או יודעים כי כל ערכיה העצמיים של A חיוביים ולכן שונים מאפס, אזי A הפיכה (מטריצה הפיכה אמ"מ 0 לא ע"ע שלה) ולכל λ ע"ע של A מתקיים λ^{-1} הינו ע"ע של A^{-1} . הוכחה: יהי x וע של A ויהי λ הע הע המתאים לו אז:

$$A^{-1} A x = x$$

$$A^{-1} A x = A^{-1} \lambda x = \lambda A^{-1} x$$

λ ע"ע של A ולכן שונה מאפס אז ניתן לחלק בו. אז $A^{-1} x = \lambda^{-1} x$ ולכן λ^{-1} הינו ע"ע של A^{-1} A^{-1} הינה SPD אז גם כל הע"ע של A^{-1} הינם חיוביים ולכן מעובדה 1 A^{-1} הינה SPD

problem 2:

נזכר כי כפל מטריצות הינו אסוציאטיבי ודיסטרביוטיבי
תהי $SPD \ Q \in M_{n \times n}(\mathbb{R})$ נראה כי $\langle \cdot, \cdot \rangle_Q : (x, y) \mapsto x^T Q y$ מכפלה פנימית.

$$\begin{aligned} \langle x, y \rangle_Q &= \langle y, x \rangle_Q \bullet \\ x, y &\in \mathbb{R}^n \text{ יהיו} \\ \langle x, y \rangle_Q &= x^T Q y = \left[\sum_{i=1}^n x_i Q_{i1}, \sum_{i=1}^n x_i Q_{i2}, \dots, \sum_{i=1}^n x_i Q_{in} \right] y = \sum_{j=1}^n y_j \sum_{i=1}^n x_i Q_{ij} = \sum_{i=1}^n \sum_{j=1}^n x_i y_j Q_{ij} \\ \langle y, x \rangle_Q &= y^T Q x = \left[\sum_{i=1}^n y_i Q_{i1}, \sum_{i=1}^n y_i Q_{i2}, \dots, \sum_{i=1}^n y_i Q_{in} \right] x = \sum_{j=1}^n x_j \sum_{i=1}^n y_i Q_{ij} = \sum_{i=1}^n \sum_{j=1}^n x_i y_j Q_{ij} \\ \langle x, y \rangle_Q &= \langle y, x \rangle_Q \text{ אז} \\ \langle \alpha x + \beta y, z \rangle_Q &= \alpha \langle x, z \rangle_Q + \beta \langle y, z \rangle_Q \bullet \\ x, y, z &\in \mathbb{R}^n \text{ יהיו} \\ \langle \alpha x + \beta y, z \rangle_Q &= (\alpha x + \beta y)^T Q z \stackrel{\text{distributive}}{=} \alpha x^T Q z + \beta y^T Q z \stackrel{\text{associative}}{=} \alpha \langle x, z \rangle_Q + \beta \langle y, z \rangle_Q \\ \forall x, \langle x, x \rangle_Q &\geq 0 \text{ מהגדרת } PD \text{ מתקיימת התכונה} \bullet \\ Qx = 0 &\iff x = 0_v \text{ כלומר } \dim(Ker(Q)) = 0 \text{ כי } SPD \text{ הינה הפיכה ולכן} \bullet \end{aligned}$$

problem 3:

תהי $SPD \ Q \in M_{n \times n}(\mathbb{F})$ ויהי $LL^T = Q$ פירוק הצ'קולסקי שלה.
 $\|x\|_Q = (x^T Q x)^{\frac{1}{2}} = (x^T L L^T x)^{\frac{1}{2}} = ((L^T x)^T (L^T x))^{\frac{1}{2}} = \left(\sum_{i=1}^n (L^T x)_i^2 \right)^{\frac{1}{2}} = \|L^T x\|_{l_2}$

Computer Exercise 1:

```
In [1]: import numpy as np
import pylab
pylab.ion()
from pylab import plt


In [2]: x2,x1 = np.mgrid[-3:3:0.01,-3:3:0.01]

In [3]: def QnormSquared(Q):
return x1**2*Q[0,0]+x2**2*Q[1,1]+2*x1*x2*Q[0,1]


In [4]: def axis_xy(g=None):
# mimics Matlab's "axis xy" command;
# making the y axis pointing upward when using imshow
if g is None:
g = plt.gca()
bottom, top = g.get_ylim()
if top<bottom:
g.set_ylim(top,bottom)

In [5]: def visualize(Q):
plt.figure()
plt.imshow((QnormSquared(Q)<1).astype(np.int64),cmap='gray')
axis_xy()
plt.colorbar()
plt.axis('off')
plt.title('x^T Q x < 1')
plt.subplots_adjust(wspace=0.4)


In [6]: Q=np.eye(2)
print ('Q=\n',Q)
visualize(Q)
```




```
In [7]: plt.figure()
plt.imshow((abs(x1)*abs(x2)<1).astype(np.int64),cmap='gray')
axis_xy()
plt.colorbar()
plt.axis('off')
plt.title('x^T L1')
plt.subplots_adjust(wspace=0.4)
```




```
In [8]: Q=np.eye(2)*np.diag([9,1])
print ('Q=\n',Q)
visualize(Q)
```



```
In [9]: Q=np.array([[9,2],[2,1]])
print ('Q=\n',Q)
visualize(Q)
```



```
In [10]: Q=np.array([[9,-2],[-2,1]])
print ('Q=\n',Q)
visualize(Q)
```



Part IV

Gaussian Random Vectors

problem 1:

$$.X = [X_1 \quad \dots \quad X_n]^T \sim N(0_{n \times 1}, I_{n \times n}) \text{ יהי}$$

$$p(x) = \frac{1}{(2\pi)^{\frac{n}{2}}} \exp(-\frac{1}{2} \|x\|_{l_2}^2) = \frac{1}{(2\pi)^{\frac{n}{2}}} \exp(-\frac{1}{2} \sum_{i=1}^n x_i^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}} \exp(-\frac{x_i^2}{2}) \text{ מהגדרה}$$

$$p(x) = \prod_{i=1}^n p_{X_i}(x_i) \text{ וגם } X_i \sim N(0, 1) \text{ אז } p_{X_i}(x) = \int_{x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n} \prod_{j=1}^n \frac{1}{\sqrt{2\pi}} \exp(-\frac{x_j^2}{2}) = \frac{1}{\sqrt{2\pi}} \exp(-\frac{x_i^2}{2}) \text{ יהי } 1 \leq i \leq n$$

באופן דומה ניתן להציג כל התפלגות שולית של מספר משתנים כמכפלה של ההתפלגויות השוליות של כל משתנה בודד וגם כל המשתנים הבודדים מתפלגים זהה אז i.i.d הם

problem 2:

$$.a, b \in \mathbb{R} \text{ ויהי } X \sim N(\mu, \sigma^2) \text{ ש } X \text{ מ"מ כד ש}$$

$$F_{aX+b}(x) = P(aX + b \leq x) = P(X \leq \frac{x-b}{a}) = \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{\frac{x-b}{a}} \exp(-\frac{1}{2}(\frac{(t-\mu)^2}{\sigma^2})) dt$$

$$\text{נציב } t = \frac{u-b}{a} \text{ אז } dt = \frac{du}{a} \text{ ונקבל כי}$$

$$\frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^{\frac{x-b}{a}} \exp(-\frac{1}{2}(\frac{(t-\mu)^2}{\sigma^2})) dt = \frac{1}{\sqrt{2\pi\sigma^2}} \int_{-\infty}^x \frac{\exp(-\frac{1}{2}(\frac{(u-b-a\mu)^2}{\sigma^2}))}{a} du = \frac{1}{\sqrt{2\pi\sigma^2 a^2}} \int_{-\infty}^x \exp(-\frac{1}{2}(\frac{(u-b-a\mu)^2}{\sigma^2})) du =$$

$$F_{aX+b}(x) = \frac{1}{\sqrt{2\pi\sigma^2 a^2}} \int_{-\infty}^x \exp(-\frac{1}{2}(\frac{(u-(b+a\mu))^2}{\sigma^2 a^2})) du$$

$$p_{aX+b}(x) = F'_{aX+b}(x) = \frac{1}{\sqrt{2\pi\sigma^2 a^2}} \exp(-\frac{1}{2}(\frac{(x-(b+a\mu))^2}{\sigma^2 a^2})) \text{ אז}$$

$$(aX + b) \sim N(a\mu + b, a^2\sigma^2) \text{ ולכן}$$

problem 3:

$$X = [X_1 \quad \dots \quad X_n]^T \sim N(\mu, \Sigma) \text{ יהי}$$

(a)

יהי $1 \leq i \leq n$ אז $X_i = [0_{1 \times i-1} \quad 1 \quad 0_{1 \times (n-i)}] X$ ולכן מעובדה 7 הינו גאוסיאני.
בנוסף מעובדה 7 מתקבל כי:

$$E(X_i) = \mu_i, \sigma_{X_i}^2 = [0_{1 \times i-1} \quad 1 \quad 0_{1 \times (n-i)}] \Sigma [0_{1 \times i-1} \quad 1 \quad 0_{1 \times (n-i)}]^T = [\Sigma_{i1} \quad \dots \quad \Sigma_{in}] [0_{1 \times i} \quad 1 \quad 0_{1 \times (n-i)}]^T = \Sigma_{ii}$$

(b)

יהיו $1 \leq k < n$ ויהיו $1 \leq i_1 < \dots < i_k \leq n$.
 נסמן $A = \begin{bmatrix} 0_{1 \times (i_1-1)} & 1 & 0_{1 \times (n-i_1)} \\ \vdots & \dots & \vdots \\ 0_{1 \times (i_k-1)} & 1 & 0_{1 \times (n-i_k)} \end{bmatrix}$ אז מעובדה $Y = AX$ הינו גאוסיאני. נשים לב כי מהגדרת A $Y = \begin{bmatrix} X_{i_1} \\ \vdots \\ X_{i_k} \end{bmatrix}$
 בנוסף מעובדה Y נקבל כי $E(Y) = A\mu_x = \begin{bmatrix} \mu_{i_1} \\ \vdots \\ \mu_{i_k} \end{bmatrix}$ וגם כי $(\Sigma_Y)_{kj} = \Sigma_{i_k i_j}$

problem 4:

יהיו $X \sim N(\mu_X, \Sigma_X)$ וקטור רנדומי ממימד n , $Y \sim N(\mu_Y, \Sigma_Y)$ וקטור רנדומי ממימד m . נניח כי $X \perp Y$.
 מהגדרת תוחלת על ו"ר ומעובדה 13 בפרק על וקטורים רנדומליים אנו מקבלים כי עבור $Z = \begin{bmatrix} X \\ Y \end{bmatrix}$, $E(Z) = \begin{bmatrix} E(X) \\ E(Y) \end{bmatrix}$, $\Sigma_Z = \begin{bmatrix} \Sigma_X & 0_{n \times m} \\ 0_{m \times n} & \Sigma_Y \end{bmatrix}$
 נראה כי $Z \sim N\left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \begin{bmatrix} \Sigma_X & 0_{n \times m} \\ 0_{m \times n} & \Sigma_Y \end{bmatrix}\right)$
 אז $p(z) = p(x, y) \stackrel{X \perp Y}{=} p(x)p(y)$

$$p(z) = \left(\frac{1}{(2\pi)^{\frac{n}{2}} |\Sigma_X|^{\frac{1}{2}}}\right) \exp\left(-\frac{1}{2} \|x - \mu_x\|_{\Sigma_X^{-1}}\right) \left(\frac{1}{(2\pi)^{\frac{m}{2}} |\Sigma_Y|^{\frac{1}{2}}}\right) \exp\left(-\frac{1}{2} \|y - \mu_y\|_{\Sigma_Y^{-1}}\right) = \frac{1}{(2\pi)^{\frac{m+n}{2}} |\Sigma_X|^{\frac{1}{2}} |\Sigma_Y|^{\frac{1}{2}}} \exp\left(-\frac{1}{2} (\|x - \mu_x\|_{\Sigma_X^{-1}} + \|y - \mu_y\|_{\Sigma_Y^{-1}})\right)$$

$$\|z - \mu_Z\|_{\Sigma_Z^{-1}} = \left(\begin{bmatrix} x \\ y \end{bmatrix} - \begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}\right)^T \begin{bmatrix} \Sigma_X & 0_{n \times m} \\ 0_{m \times n} & \Sigma_Y \end{bmatrix}^{-1} \left(\begin{bmatrix} x \\ y \end{bmatrix} - \begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}\right) = \begin{bmatrix} x - \mu_X \\ y - \mu_Y \end{bmatrix}^T \begin{bmatrix} \Sigma_X^{-1} & 0_{n \times m} \\ 0_{m \times n} & \Sigma_Y^{-1} \end{bmatrix} \begin{bmatrix} x - \mu_X \\ y - \mu_Y \end{bmatrix} =$$

$$= \begin{bmatrix} (x - \mu_X)^T \Sigma_X^{-1} \\ (y - \mu_Y)^T \Sigma_Y^{-1} \end{bmatrix}^T \begin{bmatrix} x - \mu_X \\ y - \mu_Y \end{bmatrix} = (x - \mu_X)^T \Sigma_X^{-1} (x - \mu_X) + (y - \mu_Y)^T \Sigma_Y^{-1} (y - \mu_Y) = \|x - \mu_x\|_{\Sigma_X^{-1}} + \|y - \mu_y\|_{\Sigma_Y^{-1}}$$

נשים לב כי כיוון ומדובר במטריצת בלוקים אלכסונית מתקיים כי: $\det\left(\begin{bmatrix} \Sigma_X & 0_{n \times m} \\ 0_{m \times n} & \Sigma_Y \end{bmatrix}\right) = \det(\Sigma_X) \times \det(\Sigma_Y)$
 אז קיבלנו כי $p(z) = p(x, y) \frac{1}{(2\pi)^{\frac{m+n}{2}} |\Sigma_X|^{\frac{1}{2}} |\Sigma_Y|^{\frac{1}{2}}} \exp\left(-\frac{1}{2} (\|x - \mu_x\|_{\Sigma_X^{-1}} + \|y - \mu_y\|_{\Sigma_Y^{-1}})\right) = \frac{1}{(2\pi)^{\frac{m+n}{2}} |\Sigma_Z|^{\frac{1}{2}}} \exp\left(-\frac{1}{2} \|z - \mu_Z\|_{\Sigma_Z^{-1}}\right)$
 ולכן $Z \sim N\left(\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \begin{bmatrix} \Sigma_X & 0_{n \times m} \\ 0_{m \times n} & \Sigma_Y \end{bmatrix}\right)$

problem 5:

יהיו $X \sim N(\mu_X, \Sigma_X)$, $Y \sim N(\mu_Y, \Sigma_Y)$ ו"ר ממימד n כל אחד. כך ש $X \perp Y$. נסמן $Z = X + Y$

(a)

נ.ל $Z = A \begin{bmatrix} X \\ Y \end{bmatrix}$ ש $A \in M_{n \times 2n}(\mathbb{R})$ כך ש

$$\begin{bmatrix} X \\ Y \end{bmatrix} = \begin{bmatrix} X_1 \\ \vdots \\ X_n \\ Y_1 \\ \vdots \\ Y_n \end{bmatrix}$$

$$A = \begin{bmatrix} 1 & 0_{1 \times (n-1)} & 1 & 0_{1 \times (n-2)} & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 0_{1 \times (i-1)} & 1 & 0_{1 \times (n-1)} & 1 & 0_{1 \times (n-i)} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0_{1 \times (n-2)} & 1 & 1_{1 \times (n-1)} & 0 \end{bmatrix} \text{ נבחר}$$

$$A \begin{bmatrix} X \\ Y \end{bmatrix} = \begin{bmatrix} 1 & 0_{1 \times (n-1)} & 1 & 0_{1 \times (n-2)} & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 0_{1 \times (i-1)} & 1 & 0_{1 \times (n-1)} & 1 & 0_{1 \times (n-i)} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0_{1 \times (n-2)} & 1 & 1_{1 \times (n-1)} & 0 \end{bmatrix} \begin{bmatrix} X_1 \\ \vdots \\ X_n \\ Y_1 \\ \vdots \\ Y_n \end{bmatrix} = \begin{bmatrix} X_1 + Y_1 \\ \vdots \\ X_n + Y_n \end{bmatrix} = X + Y$$

(b)

נשתמש ב A שמצאנו בסעיף א אז מעובדות 13 ו 71 אנו יודעים כי $Z \sim N\left(A \begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, A \begin{bmatrix} \Sigma_X & 0_{n \times n} \\ 0_{n \times n} & \Sigma_Y \end{bmatrix} A^T\right)$

באופן זהה לסעיף א נקבל כי $E(Z) = A \begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix} = \mu_X + \mu_Y$

$$A \begin{bmatrix} \Sigma_X & 0_{n \times n} \\ 0_{n \times n} & \Sigma_Y \end{bmatrix} A^T = \begin{bmatrix} \Sigma_X & \Sigma_Y \end{bmatrix} A^T = \Sigma_X + \Sigma_Y$$