

GMDL212, HW3

Yuval Margalit

problem1:

נגדיר פונקציה חדשה

$$\begin{aligned} L(\theta, \theta^t, \lambda) &= Q(\theta, \theta^t) - \lambda((\sum_{i=1}^K \pi_k) - 1) = (\sum_{i=1}^N \sum_{k=1}^K r_{i,k} \log \pi_k) + (\sum_{i=1}^N \sum_{k=1}^K r_{i,k} \log p(x_i; \theta_k) - \lambda((\sum_{i=1}^K \pi_k) - 1) = \\ &= (\sum_{i=1}^N \sum_{k=1}^K r_{i,k} \log \pi_k) + (\sum_{i=1}^N \sum_{k=1}^K r_{i,k} (\log(\frac{1}{(2\pi)^{\frac{n}{2}} |\Sigma_k|^{\frac{1}{2}}}) - \frac{\|x_i - \mu_k\|_{\Sigma_k^{-1}}^2}{2})) - \lambda((\sum_{i=1}^K \pi_k) - 1) \end{aligned}$$

(1)

יהי $1 \leq k \leq K$. נמצא את הנגזרות החלקיות ונשווה ל0

$$\begin{aligned} \frac{\partial L}{\partial \pi_k} &= \sum_{i=1}^N \frac{r_{i,k}}{\pi_k} - \lambda = 0 \\ \sum_{i=1}^N r_{i,k} &= \lambda \pi_k \Leftrightarrow \pi_k = \frac{\sum_{i=1}^N r_{i,k}}{\lambda} \\ \frac{\partial L}{\partial \lambda} &= \sum_{k=1}^K \pi_k - 1 = 0 \Leftrightarrow \sum_{i=1}^K \pi_k = 1 \end{aligned}$$

אז

$$\sum_{k=1}^K \pi_k = \sum_{k=1}^K \frac{\sum_{i=1}^N r_{i,k}}{\lambda} = 1$$

$$\pi_k = \frac{\sum_{i=1}^N r_{i,k}}{\lambda} = \frac{\sum_{i=1}^N r_{i,k}}{N} = \frac{N_k}{N} \text{ אז } \lambda = \sum_{k=1}^K \sum_{i=1}^N r_{i,k} = N \text{ ולכן}$$

אנו מקבלים מקסימום כיוון Q הנה concave (סכום של פונקציות concave הנו concave) והוספה של אילוף לינארי לא משנה מבחינת הקמירות/קעירות של פונקציה.

(2)

נשים לב כי הרכיב היחיד שמכיל את μ_k בפונקציה הינו $-\sum_{i=1}^N r_{i,k} \frac{\|x_i - \mu_k\|_{\Sigma_k}^{-1}}{2} = -\sum_{i=1}^N \frac{1}{2} r_{i,k} (x_i - \mu_k)^T \Sigma^{-1} (x_i - \mu_k)$ כיוון ומדובר במינוס סכום של מכפלת מספרים חיוביים נרצה למזער את הביטוי בסכום כדי למצוא את המקסימום של הפונקציה ביחס ל μ_k .
 כיוון ו Σ היא SPD קיים לה פירוק צ'קולסקי $\Sigma = LL^T$ ולכן $\Sigma^{-1} = (LL^T)^{-1} = L^{-T} L^{-1}$

$$\sum_{i=1}^N r_{i,k} (x_i - \mu_k)^T \Sigma^{-1} (x_i - \mu_k) = \sum_{i=1}^N r_{i,k} (x_i - \mu_k)^T L^{-T} L^{-1} (x_i - \mu_k) = \sum_{i=1}^N r_{i,k} \|L^{-1} (x_i - \mu_k)\|_2^2$$

אז אנחנו מחפשים את $\operatorname{argmin}_{\mu_k} \sum_{i=1}^N r_{i,k} \|L(x_i - \mu_k)\|_2$ נשים לי כי מדובר ב whigthed LLS ולכן קיים פתרון סגור.
 נגדיר $W = \operatorname{diag}(r_{1,k}, \dots, r_{1,k}, r_{2,k}, \dots, r_{2,k}, \dots, r_{N,k}, \dots, r_{N,k})$
 $H = [L^{-1}, \dots, L^{-1}]^T, y = [L^{-1}x_1, \dots, L^{-1}x_N]^T$
 כיוון ולכל i, k מתקיים כי $r_{i,k} > 0$ (לגאוסיות תמיד אינסופי) אז W הפיכה ולכן

$$\begin{aligned} \mu_k &= (H^T W H)^{-1} H^T W y = \\ &= \left(\sum_{i=1}^N r_{i,k} L^{-T} L^{-1} \right)^{-1} \sum_{i=1}^N r_{i,k} L^{-T} L^{-1} x_i = \left(\sum_{i=1}^N r_{i,k} \right)^{-1} (L)(L^T)(L^{-T})(L^{-1}) \left(\sum_{i=1}^N r_{i,k} x_i \right) = \\ &= \left(\sum_{i=1}^N r_{i,k} \right)^{-1} \left(\sum_{i=1}^N r_{i,k} x_i \right) = \frac{\sum_{i=1}^N r_{i,k} x_i}{\sum_{i=1}^N r_{i,k}} = \frac{\sum_{i=1}^N r_{i,k} x_i}{N_k} \end{aligned}$$

problem 2:

(1)

עבור $\vec{1} = \alpha$ תתקבל התפלגות אחידה מעל כל ההתפלגויות הקטגוריליות ממימד K . כיוון ולכל התפלגות קטגורילית π יתקיים כי

$$\operatorname{Dir}(\pi; \vec{1}) \propto \prod_{k=1}^K \pi_k^0 = 1$$

כלומר לכל פאי קיימת אותה הסתברות להיבחר.

(2)

π אחידה אומר ש $\pi = \frac{1}{K} \times \mathbf{1}_{1 \times K}$ כלומר הסיכוי להיות בכל קטגוריה הינו זהה.
 לעומת זאת π שהוגרלה מהתפלגות אחידה אומר שלכל התפלגות קטגורילית π' קיים אותו סיכוי להידגם.



(3)

שימוש בפריור בהקשר של π מאפשר הכנסת ידע מוקדם או הנחות כלשהן על ההתפלגות וגם מאפשר טיפול טוב יותר ברעשים בדגימה.
 בנוסף השימוש בפריור יכול למנוע הגעה למצבים מסויים (לדוגמא $\pi = [0.99, 0.01]$) שאינם רצויים.



Computer Exercise 1:

k=2



$$\alpha = 1, \Psi = 0.01I_{3 \times 3}, \nu = 3.1, \kappa = 1, m = 0.5$$





$$\alpha = 1, \Psi = 0.01I_{3 \times 3}, \nu = 1000, \kappa = 1, m = 0.5$$



$$\alpha = 100, \Psi = 0.01I_{3 \times 3}, \nu = 1000, \kappa = 10000, m = 0.5$$





$$\alpha = [30000, 1], \Psi = 0.01I_{3 \times 3}, \nu = 3.1, \kappa = 1, m = 0.5$$





k=3



$\alpha = 1, \Psi = 0.01I_{3 \times 3}, \nu = 1000, \kappa = 1, m = 0.5$





$\alpha = 100, \Psi = 0.5I_{3 \times 3}, \nu = 1000, \kappa = 15000, m = 0.5$



$$\alpha = 10000, \Psi = I_{3 \times 3}, \nu = 1000, \kappa = 1, m = 1$$





$$\alpha = 100, \Psi = \begin{bmatrix} 0.02 & 0 & 0 \\ 0 & 0.0025 & 0 \\ 0 & 0 & 0.0025 \end{bmatrix}, \nu = 1000, \kappa = 1, m = 0.5$$





k=4



$\alpha = 1, \Psi = 0.01I_{3 \times 3}, \nu = 50, \kappa = 1, m = 0.5$





$\alpha = 1, \Psi = I_{3 \times 3}, \nu = 1000, \kappa = 1, m = 0.5$



$$\alpha = 1, \Psi = 0.01 I_{3 \times 3}, \nu = 1000, \kappa = 1, m = 0.5$$



$$\alpha = 100, \Psi = 0.1 I_{3 \times 3}, \nu = 1000, \kappa = 1, m = 0.5$$



בגלל טווח הערכים הקטן בחירה של Ψ כמטריצה בעלת ערכים יחסית "גדולים" ($3\sigma \sim 0.3$: לכל צבע) מביא לכך שחלק נרחב מהטווח של הצבעים בתמונה מכוסה ע"י גאוסיות יחיד ולכן גאוסיות יחיד נבחר כמעט לכל הנקודות ובכך נוצרת סגמנטציה "רעה" כאשר הגואאסיינים האחרים נבחרים רק בנקודות "קצה" (הופכים לקבועים/כמעט קבועים). בנוסף בחירה של α באופן היוצר הבדל גדול ומשמעותי בין הגאוסיות גם היא מייצרת מצב זהה. ניתן לראות של-prior יש השפעה על איכות התוצאה ולכן בחירת prior שהינו בעל ערכים שאינם מתאמים עם pseudo count גדול יתן סגמנטציות שאינן טובות.

Problem 3:

(2)

הבחירה המתאימה של ההיפר פרמטרים תהיה כזאת הנותנת משקל חזק לlikelihood על פני הposterior. אזי נרצה pseudo count קטן ככל הניתן.

פרמטרים המתאימים לכך יהיו $\vec{m} = 0.5, \kappa = 0.1, \nu = 2.01, \alpha = 0.1, \vec{\Psi} = 0.001I$

(1)

בכדי לקבל תוצאות דומות לk-means clustering אבחר את ההיפר פרמטרים הנותנים משקל חזק לlikelihood על פני הposterior וגם בסיכוי גבוהה $\Sigma_k = \Sigma = \sigma I_{3 \times 3}$ כאשר $\sigma \rightarrow 0$ כיוון ובחירה זה מממשת k-means ב non bayesian EM GMM. היפר פרמטרים מתאים יהיו $\kappa = 0.1, \Psi = 0.000001I_{3 \times 3}, \nu = 2.01, \alpha = 0.1, \vec{m} = 0.5$